

Datenanalyse

Die **Grundgesamtheit** Ω ist die Menge der für die Untersuchung relevanten Personen oder Objekte.
Beispiele:

- Alle Personen mit Wohnsitz in Winterthur am 31. Dezember 2023
- Alle Personen die in der BMS in der Klasse 1va sind
- Alle Geräte eines bestimmten Modells, die während einer Serie produziert wurden

Eine **Stichprobe** ist eine Teilmenge der Grundgesamtheit. Die Auswahl kann zufällig oder systematisch erfolgen (z.B. befragte Personen, untersuchte Geräte, ...).


Der **Stichprobenumfang** ist die Anzahl der in der Stichprobe untersuchten Objekte.

Wird die ganze Grundgesamtheit untersucht, spricht man von einer **Vollerhebung**.

Merkmale sind Eigenschaften der **Merkmalsträger**. Zum Beispiel die Farbe (Merkmal) eines Autos (Merkmalsträger) oder Körpergrösse (Merkmal) einer Person (Merkmalsträger).

Die **Merkmalsausprägungen** sind die verschiedenen Werte, die ein Merkmal annehmen kann. (Bei den Autos z.B. Rot, Grau; bei der Körpergrösse z.B. 177 cm)

Bias/Stichprobenverzerrung ist eine systematische Abweichung durch eine nicht zufällig gezogene Stichprobe (Fragen zum öffentlichen Verkehr werden im Bahnhof wahrscheinlich anders beantwortet als am Automobilsalon)



2.1 Fehler bei der Datengewinnung:

- **Zufällige Fehler:** Wiederholte Messungen der gleichen Grösse können leichte Abweichungen zeigen
- **Systematische Fehler:** Z.B. eine Waage steht auf einer schrägen Unterlage und zeigt deshalb immer zu wenig an.
- **Übertragungsfehler:** Z.B. Zahlendreher 169 statt 196
- **Mutwillige Fehler:** Einzelne Messwerte werden geändert oder „unterschlagen“.
- **Stichprobenverzerrung:** Z.B. eine Umfrage über Ernährungsgewohnheiten von Schweizer Jugendlichen im Fitnessstudio.




3.1 Relative und Absolute Häufigkeit

Beispiel: Eine Klasse von 25 Personen konnte auswählen, welche Freizeitaktivität sie während einer Sonderwoche tätigen möchten.

Projektwoche	Strichliste	Absolute Häufigkeit	Relative Häufigkeit	Prozentuale Häufigkeit
Tennis		3	$\frac{3}{25} = 0.12$	12%
Radfahren	++++	10	$\frac{10}{25} = 0.40$	40%
Segeln		4	$\frac{4}{25} = 0.16$	16%
Schwimmen	++++	8	$\frac{8}{25} = 0.32$	32%
Gesamt	+++++	25	$\frac{25}{25} = 1$	100%

Die Häufigkeit gibt an, wie oft eine Merkmalsausprägung in der Urliste vorkommt:

- Die **Absolute Häufigkeit** gibt an, wie viele Elemente mit dem gleichen Merkmalswert gezählt wurden. Z.B. haben 3 Personen gesagt, dass sie Tennis spielen möchten.
- Die **Relative Häufigkeit** ist die Division der absoluten Häufigkeit durch den Stichprobenumfang. Sie setzt die Häufigkeit in Relation zur totalen Anzahl von Werten. Z.B. haben sich 40% der Personen für Radfahren entschieden.



3.6 Histogramm


Ein Histogramm sieht auf den ersten Blick gleich aus wie ein Säulendiagramm. Es hat aber **nicht** für jede einzelne Ausprägung eine eigene Säule, sondern es werden jeweils mehrere Ausprägungen in einer Klasse zusammengefasst.

- bei n Messwerten gilt für die Anzahl k der Klassen die Faustregel: $5 \leq k \approx \sqrt{n}$ **Wurzel der Anzahl mind. 5**
- die einzelnen Säulen grenzen direkt aneinander
- die einzelnen Klassen grenzen direkt aneinander, z.B. „[150-160[“ und „[160-170[“
- mit den Zeichen „[“ bzw. „]“ muss definiert werden, welcher Klasse ein Wert, der sich genau auf der Klassengrenze befindet, zugewiesen wird
- alle Klassen sind gleich breit (theoretisch könnten die Klassen auch unterschiedlich breit gewählt werden, wir beschränken uns aber auf Histogramme konstanter Klassenbreite)

Beispiel: die Körpergrössen (in cm) von 20 Lernenden wurden wie folgt erfasst:

154	156	159	160	161	165	167	167	170	170	172	172	174	176	176	180	180	183	187	194
-----	-----	-----	-----	-----	-----	-----	-----	-----	-----	-----	-----	-----	-----	-----	-----	-----	-----	-----	-----

Klasse	Anzahl Lernende	Relative Häufigkeit
[150-160[	3	$3/20 = 0.15$
[160-170[	5	$5/20 = 0.25$
[170-180[	7	$7/20 = 0.35$
[180-190[	4	$4/20 = 0.20$
[190-200[	1	$1/20 = 0.05$




Immer gleich breit

Achsen beschriftet
Direkt aneinander

4.1 Manipulative Darstellungen von Daten

Kein Nullpunkt



Regionalzeitung: «Grosse Unterschiede innerhalb der Parallelklassen an der Willy-Brandt-Gesamtschule»

Perspektivische Darstellung

Unterschiedliche Abstände auf einer Achse



PSD-Bank Rhein-Ruhr: «erfreulicher Geschäftsverlauf»

Ohne und mit Vergleichsgrössen

Flächendarstellung



Finanzministerium Deutschland, Erhöhung Kindergeld von 1998 - 2002

4.2 Manipulative Interpretation von Daten

Je nach Betrachtungsweise können aus gegebenen Daten komplett verschiedene Schlüsse gezogen werden.

Beispiel 1: erfolgreich oder nicht erfolgreich?

Bilanz der bisherigen Spiele von Tennisspieler F:

Spiel	Ergebnis	Platz	Ausgang
1	Australien	Rasen	verloren
2	Amerika	Hartplatz	verloren
3	Europa	Rasen	gewonnen
4	Europa	Rasen	gewonnen
5	Europa	Rasen	gewonnen
6	Europa	Hartplatz	verloren
7	Europa	Rasen	gewonnen
8	Europa	Rasen	gewonnen
9	Europa	Rasen	gewonnen
10	Europa	Rasen	gewonnen

Welche Schlagzeile darf's denn sein?

- „F im Aufwärtstrend: 70% der bisherigen Spiele gewonnen!“
- „Phänomen! F in Europa auf Rasen ohne Niederlage!“
- „F's traurige Bilanz: bisher auf Hartplatz ohne Siez!“

Beispiel 2: die Gefahren des Ehelebens

New York Times: Ursachen des Alkoholismus.

Demnach ist einer der Gründe, warum Männer oft zur Flasche greifen; die Ehefrau.

Denn: zwei Drittel aller Süßer sind verheiratet!

	Ehe (verheiratet)	Ê (nicht verheiratet)	
A _{ik} (Alkoholiker)	2	1	3
Â (nicht Alkoholiker)	10	2	12
	12	3	15

(Zahlen angepasst)

Mit einer gesamtheitlicheren Betrachtung käme man zum gegenteiligen Schluss: von den verheirateten Männern ist jeder Sechste Alkoholiker, von den nicht verheirateten jeder Dritte!

4.3 Erkennung von Manipulation

Beim Betrachten von grafischen Darstellungen sollten Sie auf die folgenden Punkte achten:

- Wer hat die Statistik in Auftrag gegeben (Quellenangaben)?
- Eignet sich die Art des Diagramms für den dargestellten Sachverhalt?
- Ist die Skalierung der Achsen linear oder nichtlinear (z.B. logarithmisch), hat sie Sprünge?
- Haben gemeinsam dargestellte Datenreihen verschiedene Achsen?
- Sind alle Daten berücksichtigt und abgebildet?

Lagemasse**Modus (x_{mod})**

Bedeutung: Wert, der am häufigsten vorkommt.

Eignung: nominal, ordinal, metrisch.

Robust? Ja (Ausreisser stören kaum).

Berechnung: Häufigkeiten zählen →

Wert mit der höchsten Häufigkeit.

Arithmetisches Mittel ($\bar{x}$)

Bedeutung: Durchschnitt aller Werte.

Eignung: nur metrisch.

Robust? Nein (Ausreisser verändern stark).

$$\bar{x} = \frac{x_1 + x_2 + x_3 + \dots + x_n}{n}$$

Median (Zentralwert z)

Bedeutung: Mittlerer Wert einer sortierten Liste.

Eignung: ordinal, metrisch.

Robust? Ja.

Berechnung:

ungerade Anzahl: mittlerer Wert

gerade Anzahl: Durchschnitt der beiden mittleren Werte

Streuungsmaße**Spannweite (Range R)**

Bedeutung: Abstand zwischen dem grössten und kleinsten Wert.

Robust? Nein.

Berechnung:

Differenz zwischen dem grössten und dem kleinsten Wert

Standardabweichung (s)

Bedeutung: Wie stark die Werte um den Mittelwert streuen.

Klein s: Werte liegen nahe beim Durchschnitt.

Gross s: Werte sind weit verteilt.

Robust? Nein.

Interquartilsabstand (IQR = Q3 - Q1)

Bedeutung: Breite der mittleren 50% der Werte.

Robust? Ja.

```
liste := { 7, 8, 8, 9, 9, 11, 15, 21 }
          { 7, 8, 8, 9, 9, 11, 15, 21 }
```

OneVar liste

Fertig

stat.results

"Titel"	"Statistik mit einer Varia	
" $\bar{x}$ "	Durchschnitt	11.
" Σx "	alle addiert	88.
" Σx^2 "		1126.
"SX := $S_{n-1}x$ "		4.75094
"OX := σ_{nX} "	Standartabw	4.4441
"n"	Anzahl	8.
"MinX"		7.
"Q ₁ X"		8.
"MedianX"	Median	9.
"Q ₃ X"		13.
"MaxX"		21.
"SSX := $\Sigma(x - \bar{x})^2$ "		158.


8. Korrelation und Kausalität**8.1 Korrelation**

Im Folgenden sind Daten, die aus jeweils zwei Merkmalen bestehen, dargestellt.


Korrelation bedeutet: es gibt einen **Zusammenhang** zwischen zwei Merkmalen oder Zahlen.

Zusammenhang


Beispiel 1:



Beispiel 2:



Beispiel 3²:

**8.2 Kausalität**

Korrelationsstatistiken werden häufig als „Beweis“ für Behauptungen zu Ursache und Wirkung (Kausalität) missbraucht.

Aber: macht Schokolade wirklich schlau? Oder umgekehrt: führt ein Nobelpreis zu einem höheren Schokoladenkonsum? Oder sind Nobelpreise und ein hoher Schokoladenkonsum vielleicht beides die Folge von „Reichtum“?

Von Kausalität spricht man nur, wenn ein Merkmal tatsächlich das andere Merkmal beeinflusst. D.h. wenn ein Merkmal eine Ursache des anderen ist.

Kausalität bedeutet: zwei Merkmale oder Zahlen stehen **ursächlich** zueinander.

Ursache → Wirkung

Boxplots erstellen

- Messwerte sortieren und zählen: **n**
- Linie mit passender Skala zeichnen
- Median **z** bestimmen:
 - n ungerade: **z = mittlerer Wert**
 - n gerade: **z = arithmetisches Mittel der zwei mittleren Werte**
- Quartile **Q₁**, **Q₃** bestimmen:
 - n ungerade: Median **z** wird für Berechnung nicht berücksichtigt
 - n gerade: die zwei mittleren Werte werden berücksichtigt
- Box zeichnen
- Quartilsabstand **IQR** bestimmen: **IQR = Q₃ - Q₁**
- Ausreisserschwelle unten bestimmen: **AS_u = Q₁ - 1.5 · IQR**
- Ausreisserschwelle oben bestimmen: **AS_o = Q₃ + 1.5 · IQR**
- Ausreisserschwelle fein (ausradierbar) einzeichnen
- Unterer Fühler einzeichnen: bis zum tiefsten Messwert vor der Ausreisserschwelle
Oberer Fühler einzeichnen: bis zum höchsten Messwert vor der Ausreisserschwelle
- Allfällige Ausreisser als kleine Ringe einzeichnen