

# IDAF - Datenanalyse

Die **Grundgesamtheit**  $\Omega$  ist die Menge der für die Untersuchung relevanten Personen oder Objekte.

- Beispiele:
- Alle Personen mit Wohnsitz in Winterthur am 31. Dezember 2023
  - Alle Personen die in der BMS in der Klasse 1va sind
  - Alle Geräte eines bestimmten Modells, die während einer Serie produziert wurden

Eine **Stichprobe** ist eine Teilmenge der Grundgesamtheit. Die Auswahl kann zufällig oder systematisch erfolgen (z.B. befragte Personen, untersuchte Geräte, ...).


Der **Stichprobenumfang** ist die Anzahl der in der Stichprobe untersuchten Objekte.

Wird die ganze Grundgesamtheit untersucht, spricht man von einer **Vollerhebung**.

**Merkmale** sind Eigenschaften der **Merkmalsträger**. Zum Beispiel die Farbe (Merkmal) eines Autos (Merkmalsträger) oder Körpergröße (Merkmal) einer Person (Merkmalsträger).

Die **Merkmalsausprägungen** sind die verschiedenen Werte, die ein Merkmal annehmen kann. (Bei den Autos z.B. Rot, Grau; bei der Körpergröße z.B. 177 cm)

**Bias/Stichprobenverzerrung** ist eine systematische Abweichung durch eine nicht zufällig gezogene Stichprobe (Fragen zum öffentlichen Verkehr werden im Bahnhof wahrscheinlich anders beantwortet als am Automobilsalon)



## 2.1 Fehler bei der Datengewinnung:

- **Zufällige Fehler:** Wiederholte Messungen der gleichen Größe können leichte Abweichungen zeigen.
- **Systematische Fehler:** Z.B. eine Waage steht auf einer schrägen Unterlage und zeigt deshalb immer zu wenig an.
- **Übertragungsfehler:** Z.B. Zahlendreher 169 statt 196
- **Mutwillige Fehler:** Einzelne Messwerte werden geändert oder „unterschlagen“.
- **Stichprobenverzerrung:** Z.B. eine Umfrage über Ernährungsgewohnheiten von Schweizer Jugendlichen im Fitnessstudio.



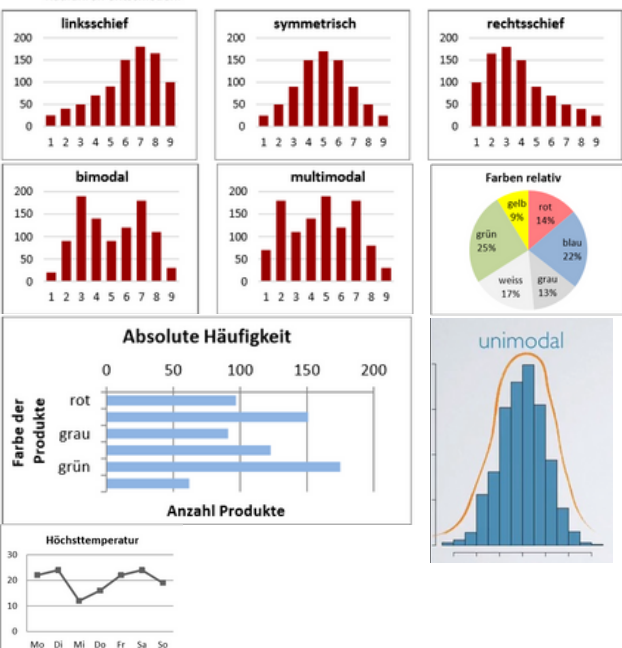
## 3.1 Relative und Absolute Häufigkeit

Beispiel: Eine Klasse von 25 Personen konnte auswählen, welche Freizeitaktivität sie während einer Sonderwoche tätigen möchten.

| Projektwoche | Strichliste | Absolute Häufigkeit | Relative Häufigkeit    | Prozentuale Häufigkeit |
|--------------|-------------|---------------------|------------------------|------------------------|
| Tennis       |             | 3                   | $\frac{3}{25} = 0.12$  | 12%                    |
| Radfahren    | ++++        | 10                  | $\frac{10}{25} = 0.40$ | 40%                    |
| Segeln       |             | 4                   | $\frac{4}{25} = 0.16$  | 16%                    |
| Schwimmen    | ++++        | 8                   | $\frac{8}{25} = 0.32$  | 32%                    |
| Gesamt       | +++++       | 25                  | $\frac{25}{25} = 1$    | 100%                   |

Die Häufigkeit gibt an, wie oft eine Merkmalsausprägung in der Urliste vorkommt:

- Die **Absolute Häufigkeit** gibt an, wie viele Elemente mit dem gleichen Merkmalswert gezählt wurden. Z.B. haben 3 Personen gesagt, dass sie Tennis spielen möchten.
- Die **Relative Häufigkeit** ist die Division der absoluten Häufigkeit durch den Stichprobenumfang. Sie setzt die Häufigkeit in Relation zur totalen Anzahl von Werten. Z.B. haben sich 40% der Personen für Radfahren entschieden.



## 3.6 Histogramm


Ein Histogramm sieht auf den ersten Blick gleich aus wie ein Säulendiagramm. Es hat aber **nicht** für jede einzelne Ausprägung eine eigene Säule, sondern es werden jeweils mehrere Ausprägungen in einer Klasse zusammengefasst.

- bei  $n$  Messwerten gilt für die Anzahl  $k$  der Klassen die Faustregel:  $5 \leq k \approx \sqrt{n}$  **Wurzel der Anzahl mind. 5**
- die einzelnen Säulen grenzen direkt aneinander
- die einzelnen Klassen grenzen direkt aneinander, z.B. „[150-160]“, und „[160-170]“, mit den Zeichen „[“, bzw. „]“ muss definiert werden, welcher Klasse ein Wert, der sich genau auf der Klassengrenze befindet, zugewiesen wird
- alle Klassen sind gleich breit (theoretisch könnten die Klassen auch unterschiedlich breit gewählt werden, wir beschränken uns aber auf Histogramme konstanter Klassenbreite)

Beispiel: die Körpergrößen (in cm) von 20 Lernenden wurden wie folgt erfasst:

|     |     |     |     |     |     |     |     |     |     |     |     |     |     |     |     |     |     |     |     |
|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|
| 154 | 156 | 159 | 160 | 161 | 165 | 167 | 167 | 170 | 170 | 172 | 172 | 174 | 176 | 176 | 180 | 180 | 183 | 187 | 194 |
|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|

| Klasse    | Anzahl Lernende | Relative Häufigkeit |
|-----------|-----------------|---------------------|
| [150-160[ | 3               | $3/20 = 0.15$       |
| [160-170[ | 5               | $5/20 = 0.25$       |
| [170-180[ | 7               | $7/20 = 0.35$       |
| [180-190[ | 4               | $4/20 = 0.20$       |
| [190-200[ | 1               | $1/20 = 0.05$       |




Immer gleich breit

Achsen beschriften  
Direkt aneinander


## 4.1 Manipulative Darstellungen von Daten

Kein Nullpunkt




Regionalzeitung: «Grosse Unterschiede innerhalb der Parallelklassen an der Willy-Brandt-Gesamtschule»

Unterschiedliche Abstände auf einer Achse



PSD-Bank Rhein-Ruhr: «erfreulicher Geschäftsverlauf»

Fächendarstellung



Finanzministerium Deutschland, Erhöhung Kindergeld von 1998 - 2002

## 4.2 Manipulative Interpretation von Daten

Je nach Betrachtungsweise können aus gegebenen Daten komplett verschiedene Schlüsse gezogen werden.

Beispiel 1: erfolgreich oder nicht erfolgreich?

Bilanz der bisherigen Spiele von Tennisspieler F:

| Spiel | Erdeiten   | Platz     | Ausgang  |
|-------|------------|-----------|----------|
| 1     | Australien | Rasen     | verloren |
| 2     | Amerika    | Hartplatz | verloren |
| 3     | Europa     | Rasen     | gewonnen |
| 4     | Europa     | Rasen     | gewonnen |
| 5     | Europa     | Rasen     | gewonnen |
| 6     | Europa     | Hartplatz | verloren |
| 7     | Europa     | Rasen     | gewonnen |
| 8     | Europa     | Rasen     | gewonnen |
| 9     | Europa     | Rasen     | gewonnen |
| 10    | Europa     | Rasen     | gewonnen |

Welche Schlagzeile darf's denn sein?

- „F im Aufwärtstrend: 70% der bisherigen Spiele gewonnen!“
- „Phänomenal! F in Europa auf Rasen ohne Niederlage!“
- „F's traurige Bilanz: bisher auf Hartplatz ohne Sieg!“

Beispiel 2: die Gefahren des Ehelebens

New York Times: Ursachen des Alkoholismus.

Demnach ist einer der Gründe, warum Männer oft zur Flasche greifen; die Ehefrau.

Denn: zwei Drittel aller Säuer sind verheiratet!

|                                       | E <sub>he</sub><br>(verheiratet) | E <sub>!</sub><br>(nicht verheiratet) |    |
|---------------------------------------|----------------------------------|---------------------------------------|----|
| A <sub>ik</sub><br>(Alkoholiker)      | 2                                | 1                                     | 3  |
| A <sub>!</sub><br>(nicht Alkoholiker) | 10                               | 2                                     | 12 |
|                                       | 12                               | 3                                     | 15 |

(Zahlen angepasst)

Mit einer gesamtheitlicheren Betrachtung käme man zum gegenteiligen Schluss: von den verheirateten Männern ist jeder Sechste Alkoholiker, von den nicht verheirateten jeder Drittel